

# MICHAEL NEWTON CUTIPA SANTI

## CareER-GPT: Arquitectura Híbrida con LoRA sobre LLMs y Modelos Tabulares para la 3 Generación y Ranqueo de Rutas Ed...



Universidad Nacional del Altiplano

### Detalles del documento

Identificador de la entrega

trn:oid:::8254:601298840

Fecha de entrega

19 jun 2026, 8:14 p.m. GMT-5

Fecha de descarga

9 jul 2026, 11:20 a.m. GMT-5

Nombre del archivo

CareER-GPT\_ Arquitectura Híbrida con LoRA sobre LLMs y Modelos Tabulares para la Generación ....pdf

Tamaño del archivo

541.6 KB

21 páginas

10.113 palabras

56.779 caracteres

# 8% Similitud general

El total combinado de todas las coincidencias, incluidas las fuentes superpuestas, para ca...

## Filtrado desde el informe

- ▶ Bibliografía
- ▶ Texto citado
- ▶ Texto mencionado
- ▶ Coincidencias menores (menos de 10 palabras)

## Fuentes principales

- 5%  Fuentes de Internet
- 1%  Publicaciones
- 6%  Trabajos entregados (trabajos del estudiante)

## Marcas de integridad

### N.º de alertas de integridad para revisión

No se han detectado manipulaciones de texto sospechosas.

Los algoritmos de nuestro sistema analizan un documento en profundidad para buscar inconsistencias que permitirían distinguirlo de una entrega normal. Si advertimos algo extraño, lo marcamos como una alerta para que pueda revisarlo.

Una marca de alerta no es necesariamente un indicador de problemas. Sin embargo, recomendamos que preste atención y la revise.

### Fuentes principales

- 5% Fuentes de Internet
- 1% Publicaciones
- 6% Trabajos entregados (trabajos del estudiante)

### Fuentes principales

Las fuentes con el mayor número de coincidencias dentro de la entrega. Las fuentes superpuestas no se mostrarán.

|    |                     |                                                 |     |
|----|---------------------|-------------------------------------------------|-----|
| 1  | Trabajos entregados | Universidad Nacional de Juliaca on 2026-05-31   | <1% |
| 2  | Internet            | repositorio.unfv.edu.pe                         | <1% |
| 3  | Internet            | repositorio.usfq.edu.ec                         | <1% |
| 4  | Trabajos entregados | unap on 2024-10-03                              | <1% |
| 5  | Internet            | revista.ister.edu.ec                            | <1% |
| 6  | Internet            | riti.es                                         | <1% |
| 7  | Internet            | sedici.unlp.edu.ar                              | <1% |
| 8  | Trabajos entregados | Universidad Autónoma de Querétaro on 2025-11-21 | <1% |
| 9  | Internet            | view.genial.ly                                  | <1% |
| 10 | Trabajos entregados | Universidad Nacional de Juliaca on 2026-06-14   | <1% |
| 11 | Trabajos entregados | Universidad de Guayaquil on 2025-05-17          | <1% |

|    |                     |                                                                                       |     |
|----|---------------------|---------------------------------------------------------------------------------------|-----|
| 12 | Publicación         | Gonzales Mendoza, Felipe Santiago. "Análisis fisicoquímico y mitigación de la cali... | <1% |
| 13 | Publicación         | Zavala Jara, Yesenia Eusebia. "Comparación de días y costos hospitalarios entre di... | <1% |
| 14 | Internet            | www.scielo.org.mx                                                                     | <1% |
| 15 | Trabajos entregados | Health and Kinesiology on 2025-08-14                                                  | <1% |
| 16 | Trabajos entregados | Universidad del Norte, Colombia on 2025-02-24                                         | <1% |
| 17 | Internet            | oulurepo.oulu.fi                                                                      | <1% |
| 18 | Trabajos entregados | Universidad Europea de Madrid on 2025-07-06                                           | <1% |
| 19 | Trabajos entregados | Universidad Internacional de la Rioja on 2025-02-23                                   | <1% |
| 20 | Trabajos entregados | Universidad Nacional de Educacion Enrique Guzman y Valle on 2025-09-18                | <1% |
| 21 | Trabajos entregados | Universidad de Lima on 2020-12-07                                                     | <1% |
| 22 | Internet            | www.coursehero.com                                                                    | <1% |
| 23 | Trabajos entregados | Universidad Europea de Madrid on 2026-06-09                                           | <1% |
| 24 | Trabajos entregados | Universidad de Manizales on 2026-05-10                                                | <1% |
| 25 | Trabajos entregados | Universitat Politècnica de València on 2021-01-13                                     | <1% |

|    |                     |                                                                                     |     |
|----|---------------------|-------------------------------------------------------------------------------------|-----|
| 26 | Internet            | geoecotrop.be                                                                       | <1% |
| 27 | Internet            | repositorio.uap.edu.pe                                                              | <1% |
| 28 | Internet            | repositorio.uloyola.es                                                              | <1% |
| 29 | Trabajos entregados | tarapoto on 2024-01-04                                                              | <1% |
| 30 | Trabajos entregados | Colegio Columbia on 2024-07-08                                                      | <1% |
| 31 | Publicación         | García, Juan Fernando Chica. "Metodología de Análisis y Mejoramiento de la Logís... | <1% |
| 32 | Trabajos entregados | UNIBA on 2025-11-10                                                                 | <1% |
| 33 | Trabajos entregados | Universidad Andrés Bello on 2024-11-22                                              | <1% |
| 34 | Internet            | diposit.ub.edu                                                                      | <1% |
| 35 | Internet            | editoraartemis.com.br                                                               | <1% |
| 36 | Internet            | repositorioacademico.upc.edu.pe                                                     | <1% |
| 37 | Trabajos entregados | unap on 2025-08-07                                                                  | <1% |
| 38 | Internet            | upcommons.upc.edu                                                                   | <1% |
| 39 | Internet            | www.researchgate.net                                                                | <1% |

## 1 TÍTULO DEL PROYECTO

2  
3 CareER-GPT: Arquitectura Híbrida con LoRA sobre LLMs y Modelos Tabulares para la  
4 Generación y Ranqueo de Rutas Educativas en Postulantes de la Región de Puno

## 5 AUTOR:

6 Michael Newton Cutipa Santi michael.cutipa@unap.edu.pe

7 **LÍNEA DE INVESTIGACIÓN:** Inteligencia de negocios y datos

8 **SUB-LÍNEA DE INVESTIGACIÓN:** BI, Big Data, ML, visualización de datos

## 9 RESUMEN:

10 La orientación vocacional en Perú enfrenta desafíos significativos, principalmente por el uso de  
11 herramientas y métodos tradicionales que no toman en cuenta los datos históricos de los postulantes a la  
12 universidad; esto ha llevado a un índice de deserción universitaria y a elecciones de carreras poco  
13 adecuadas. Este fenómeno se debe, en gran parte, a la falta de personalización en los enfoques actuales, que  
14 no logran ofrecer recomendaciones precisas basadas en el perfil único de cada postulante. Con el objetivo  
15 de superar estas dificultades este trabajo tiene como propósito desarrollar el modelo CareER-GPT, una  
16 arquitectura híbrida de inteligencia artificial que combina modelos tabulares (XGBoost) para el ranqueo de  
17 probabilidades de éxito y modelos de lenguaje grande (LLMs) ajustados mediante LoRA para la generación  
18 de rutas educativas personalizadas. La metodología incluye la preparación de dos datasets conformados por  
19 los postulantes a la universidad Nacional del Altiplano (UNA), del 2022-I y 2025-II y el registro del  
20 **rendimiento académico de los egresados de las Instituciones Educativas Secundarias de la región Puno**, así  
21 mismo la transformación de datos en pares prompt-respuesta, entrenamiento de modelos e integración en  
22 un sistema unificado. Los resultados que se esperan son la inclusión de la validación de la arquitectura y su  
23 superioridad ante métodos tradicionales, contribuyendo a la optimización de la orientación vocacional en  
24 contextos educativos. Además, este modelo brindara herramientas más efectivas y basadas en datos.  
25 Finalmente, el proyecto busca mejorar la calidad educativa en regiones como Puno, optimizando el proceso  
26 de selección de carrera para futuros universitarios.

27 **Palabras clave:** LLMs, LoRA, modelos de lenguaje, orientación vocacional, XGBoost

## 28 ABSTRACT:

29 Vocational guidance in Peru faces significant challenges, mainly due to the use of traditional tools and  
30 **methods that do not take into account the historical data of university applicants; this has led to a high**  
31 **university dropout rate and poor career choices.** This phenomenon is largely due to the lack of  
32 personalisation in current approaches, which fail to offer accurate recommendations based on each  
33 applicant's unique profile. With the aim of overcoming these difficulties, this work aims to develop the  
34 CareER-GPT model, a hybrid artificial intelligence architecture that combines tabular models (XGBoost)  
35 for ranking probabilities of success and large language models (LLMs) adjusted using LoRA for the  
36 generation of personalised educational pathways. The methodology includes the preparation of two datasets  
37 made up of applicants to the National University of the Altiplano (UNA) from 2022-I and 2025-II and the  
38 recording of the academic performance of graduates from secondary educational institutions in the Puno  
39 region, as well as the transformation of data into prompt-response pairs, model training, and integration  
40 into a unified system. The expected results include the validation of the architecture and its superiority over  
41 traditional methods, contributing to the optimisation of vocational guidance in regional educational

contexts. In addition, this model will provide more effective, data-driven tools. Finally, the project seeks to improve educational quality in regions such as Puno by optimising the career selection process for future university students.

**Keywords: LLMs, LoRA, language models, orientation vocational, XGBoost**

## **I. PLANTEAMIENTO DEL PROBLEMA**

En la actualidad, la deserción universitaria constituye uno de los problemas estructurales más serios que afectan a los sistemas de educación superior y al desarrollo socioeconómico en el ámbito mundial. La evidencia internacional coincide en que el abandono se concentra en los primeros años de estudio, etapa en la que los estudiantes enfrentan las mayores dificultades de adaptación académica, emocional y vocacional, lo que convierte la transición de la educación secundaria a la superior en el periodo más vulnerable de la trayectoria universitaria. Este fenómeno no solo conlleva pérdidas personales y familiares, sino que también representa costos significativos para las instituciones educativas y para la sociedad, al desperdiciarse un capital humano que podría ser altamente productivo.

En América Latina la magnitud del problema es particularmente alta. De acuerdo con el Banco Mundial, cerca de la mitad de la población de 25 a 29 años que inició estudios superiores no llegó a culminarlos (Ferreira et al., 2017), mientras que estimaciones de la UNESCO ubican entre el 30% y el 50% la proporción de estudiantes universitarios que no concluyen sus estudios. Las cifras de deserción en el primer año confirman esta tendencia, con valores cercanos al 31% en Colombia, 21% en Chile y 33% en el Perú hacia el año 2019, antes del inicio de la pandemia (Behr, 2020).

En el caso peruano, la situación no es distinta. Según el II Informe Bienal sobre la Realidad Universitaria elaborado por la SUNEDU, alrededor del 15.8% de los estudiantes abandonó las aulas universitarias a nivel nacional entre los años 2012 y 2018, y la limitada disponibilidad de herramientas de orientación vocacional basadas en evidencia agrava este panorama. Según Escalante y Vásquez (2023), la deserción universitaria en Perú sigue siendo un problema sin resolver, y esto se debe a una variedad de factores, como los económicos, familiares, vocacionales y de motivación. Estos autores subrayan que la falta de una orientación adecuada y de estrategias preventivas por parte de las instituciones limita la permanencia de los estudiantes, lo que genera un impacto social y económico que va más allá del ámbito educativo.

En la región de Puno este panorama se intensifica debido a las marcadas desigualdades socioeconómicas y geográficas del Altiplano y al limitado acceso a información vocacional personalizada. Estudios recientes confirman que la deserción y el bajo rendimiento académico representan desafíos críticos para la Universidad Nacional del Altiplano de Puno (Cuentas Yupanqui, 2024), institución en la que la inteligencia artificial ha mostrado potencial para mejorar el rendimiento académico de los estudiantes (Rodríguez, 2023). Entre las causas locales destaca la ausencia de sistemas predictivos que integren los datos académicos históricos de los postulantes, mientras que sus efectos se manifiestan en elecciones vocacionales inadecuadas, bajo rendimiento académico y un mayor abandono estudiantil. Ante esta situación, se hace evidente la necesidad de buscar soluciones tecnológicas innovadoras que incorporen inteligencia artificial (IA) en los procesos de orientación vocacional y en la predicción del éxito académico.

En particular, la implementación de una arquitectura híbrida de IA que combine modelos tabulares con grandes modelos de lenguaje (LLMs) ajustados mediante técnicas como LoRA podría facilitar la creación de rutas educativas personalizadas y contextualizadas, adaptadas a las características de los postulantes a universidades. Razón por la cual surgen las siguientes interrogantes.

**Problema General:**

¿En qué medida una arquitectura híbrida de IA que combine modelos tabulares y LLMs con LoRA puede optimizar la generación y ranqueo de rutas educativas personalizadas para postulantes universitarios de Puno?

### Problemas Específicos:

¿Cómo afecta el rendimiento académico previo en la predicción del éxito universitario?

¿Qué variables académicas y socioeducativas son más determinantes en la creación de rutas educativas personalizadas?

¿Qué efectividad tiene el ajuste fino con LoRA en la contextualización de recomendaciones educativas para diferentes perfiles estudiantiles?

## II. JUSTIFICACIÓN

La deserción universitaria es un desafío serio en la educación superior de Perú, especialmente en la región de Puno. Una zona que enfrenta grandes desigualdades en el acceso a información y apoyo para elegir carreras profesionales. Además, hay una brecha notable entre las habilidades de los postulantes y las rutas educativas que deciden seguir, lo que impacta directamente en la deserción universitaria y en la falta de coincidencia entre habilidades, intereses y trayectorias formativas. (Rodas, 2024) Así mismo la falta de orientación vocacional afecta la permanencia estudiantil ya que muchas veces los postulantes deciden por una carrera sin una información previa y adecuada lo cual genera que la abandonen a mitad de sus estudios y opten por otra. Esta investigación surge de la necesidad de proporcionar herramientas tecnológicas innovadoras y escalables que no solo ayuden a predecir el rendimiento académico de los estudiantes, sino que también ofrezcan itinerarios educativos personalizados y coherentes, lo que les permita tomar decisiones informadas sobre su futuro académico. En este contexto, se ha desarrollado el marco híbrido de inteligencia artificial denominado CareER-GPT. La optimización de la orientación vocacional hará que los estudiantes elijan un programa académico adecuado, que se ajusten a sus capacidades y habilidades, y se estima que esto reduzca la deserción universitaria en gran medida. Esta propuesta no solo atenderá a las necesidades urgentes de los estudiantes, sino que a su vez fortalecerá la capacidad de orientación vocacional de las universidades de la región de Puno para poder retener a su talento. Se mejorarán las tasas de retención académica al fomentar un proceso de recomendaciones más personalizadas y adaptadas a las características de cada solicitante, lo que permitirá que se forme más profesional, es para el desarrollo de la región. Por otra parte, esta labor cubrirá un vacío importante en la aplicación de arquitecturas híbridas de inteligencia artificial (IA) en educación, especialmente importante en entornos con disponibilidad de datos limitados. La combinación de la adaptación de bajo nivel (LoRA) con los modelos de lenguaje grandes (LLM) ofrecerá un enfoque fácil de replicar y escalar que no solo se adapta a la disponibilidad de recursos, sino que también eleva la personalización de la orientación educativa. Esto representa una vía en gran medida inexplorada dentro de los campos orientados a la carrera profesional en regiones con un avance tecnológico limitado.

## III. HIPÓTESIS

**Hipótesis general:** La arquitectura híbrida CareER-GPT, basada en LoRA sobre LLMs y modelos tabulares, genera y rankea rutas educativas personalizadas con una precisión significativamente alta para los postulantes de la región de Puno.

### Hipótesis específicas:

La transformación del conjunto de datos de postulantes en pares prompt-respuesta permite generar un corpus sintético representativo, coherente y balanceado del perfil académico y vocacional, adecuado para el entrenamiento del modelo de lenguaje

El modelo tabular XGBoost clasifica con al menos un 85% de precisión la probabilidad de éxito por carrera.

El fine-tuning con LoRA permite al LLM generar rutas educativas con coherencia contextual superior al 80%.

La integración híbrida supera el rendimiento de cada modelo por separado en al menos un 10%.

## IV. OBJETIVOS

### 4.1 Objetivo General

Desarrollar y validar la arquitectura híbrida CareER-GPT, basada en LoRA sobre LLMs y modelos tabulares, para la generación y ranqueo de rutas educativas personalizadas en postulantes de la región de Puno

### 4.2 Objetivos Específicos

- Preparar y transformar el dataset de 12,000 postulantes en pares prompt-respuesta para el entrenamiento de modelos.
- Entrenar y evaluar un modelo tabular (XGBoost) para el ranqueo de probabilidades de éxito por carrera.
- Ajustar un LLM mediante LoRA para la generación automática de rutas educativas contextualizadas.
- Integrar ambos modelos en una arquitectura unificada y validar su eficacia comparativa.

## V. ANTECEDENTES

### 5.1. Internacionales:

García y Serradilla (2021) tuvieron como objetivo desarrollar técnicas de clasificación de textos que alcancen el estado del arte sin requerir grandes recursos computacionales, ampliar los modelos del lenguaje para el español dada la falta de recursos adecuados para esta lengua en PLN. Su metodología se centró en el uso de modelos basados en la arquitectura Transformers y BERT para la clasificación de textos, Los obtenidos están alineados con el estado del arte destacando la eficiencia de modelos de tamaño moderado y abierto. Se concluye que, a pesar de los avances en PLN, hay un desinterés en la industria y academia por los modelos neuronales para el idioma español, lo que representa un nicho importante para el desarrollo de recursos en este idioma.

Mena (2023) se propuso evaluar el uso de modelos de lenguaje masivos en español, comparar tres modelos (LLaMA2-Chat, Mistral, FALCON) y estudiar las posibilidades de adaptar estos modelos para generar chatbots en Ecuador, la metodología que utilizó fue probar los modelos de lenguaje masivo con 7 billones de parámetros, luego adaptarlos mediante técnicas de Quantized Low Rank Adaptation (QLoRA), los resultados a los que arriba fue que los tres modelos mejoraron después del ajuste, destacando Mistral en tareas complejas y Falcon en tareas creativas por otro lado los modelos ajustados mostraron un desempeño inferior a sus versiones base y respuestas imprecisas. Concluyo que la falta de VRAM fue una limitación importante, pero se logró fine tunear los modelos con éxito; mistral tuvo el mejor desempeño global y se recomienda explorar tecnologías como RAG y MoE para futuras mejoras.

Hu et al.(2021) buscaron aplicar el método de Low Rank Adaptation para entrenar parámetros específicos de tareas adaptadas sin modificar, obtuvieron resultados donde demostraron que LoRA es competitivo en tareas de comprensión de lenguaje natural (como GLUE, WikiSQL) al ser comparado con enfoques tradicionales de fine.tuning, llegando a la conclusión de que LoRA reduce significativamente los requisitos de memoria el costo computacional y el tiempo de entrenamiento en comparación con el fine tuning completo sin afectar el rendimiento.

Armando et al. (2023), realizaron una investigación denominada “ URKU: Adaptacion de LlaMA 2 para la generación de texto en kichwa usando técnicas de Low.Rank Adaptation (LoRA)”, tuvieron como

propósito adaptar el modelo LLaLA 2 al idioma Kichwa mediante técnicas de procesamiento de lenguaje natural (NLP), así mismo crear un corpus de alta calidad para entrenar el modelo, utilizando LoRA para adaptarlo y establecer un benchmark para la evaluación, generación y traducción de textos por el modelo adaptado, los resultados que obtuvieron son que el modelo URKU ha demostrado un rendimiento significativo en la generación de texto en kichwa superando así a modelos previos, se destacó como un factor clave el éxito del modelo. La conclusión que obtuvieron es que el modelo URKU es un avance significativo para la inclusión lingüística y la preservación cultural, ofreciendo un modelo de procesamiento de lenguaje natural adecuado para idiomas con recursos limitados.

Castejon (2025) Busco diseñar, implementar y evaluar un sistema conversacional inteligente que permita interactuar en lenguaje natural con información del Museo Sorolla, el estudio correspondió a preguntas que usuarios reales podrían realizar sobre el museo, los cuales estaban estructuradas en categorías de uso del sistema, los resultados a los que arribó fue que el clasificador de intención dio como precisión global un 88%, F1-Score 0,88 y Clase SQL con mejor rendimiento en 0,94, así mismo en RAG preguntas abiertas obtuvo como context Relevance 0.98 y faithfulness 0,67, mencionando que cuando se usa correctamente ingeniería de prompts demuestra cero alucinaciones. Concluyo que SoroIA funciona eficazmente como sistema conversacional para un museo integrando LLM, RAG, Text2SQL con resultados robustos.

Fang et al. (2024) presentan una revisión extensiva de las investigaciones recientes en modelos de lenguaje grandes (LLMs) para una amplia variedad de tareas relacionadas con datos tabulares: predicción, generación de datos y la comprensión de tablas. El objetivo de su revisión fue llevar a cabo un análisis exhaustivo sobre el estado del arte de los modelos LLMs en relación a las técnicas, métricas y enfoques utilizados y, además, resaltar las ventajas que presentan estos modelos de lenguaje en comparación con los árboles de decisión en conjuntos de datos grandes y heterogéneos. Sus resultados indicaron la gran capacidad de los LLMs para realizar tareas complejas a expensas de ciertos puntos débiles a mejorar, como la generalización y la interpretabilidad. concluyeron mencionando que, pese a su gran capacidad, es necesario avanzar en la investigación para mejorar su rendimiento y su adaptabilidad a diferentes conjuntos de datos o tareas.

Fernandez et al. (2025) se enfocaron en cómo podemos enseñar trucos nuevos a los modelos de inteligencia artificial (los llamados modelos de lenguaje grande) para que se conviertan en mejores tutores de matemáticas y física en la escuela. A través de un proceso llamado "ajuste fino" (fine-tuning), tomaron modelos ya entrenados y los pusieron a practicar intensamente con problemas específicos, como los del conjunto de datos GSM8K (que incluye ejercicios de primaria y secundaria). Los resultados demostraron que esta "clase particular" funciona de maravilla: el ajuste fino no solo hace que la IA sea mucho mejor y más precisa para resolver los problemas de estas asignaturas complejas, sino que también facilita la forma en que explica los conceptos, volviéndose una herramienta educativa muy valiosa y aplicada, especialmente en el mundo de la ciencia y los números.

Ramos-Rivera et al. (2025) analizaron cómo se pueden aplicar los modelos de lenguaje grandes (LLM) para mejorar la calidad analítica de las respuestas abiertas en las evaluaciones del rendimiento docente. A través de tres metodologías clave modelos específicos de dominio, modelos de lenguaje pequeños (SLM) y modelos basados en la nube que emplean «menos iteraciones de entrenamiento», los investigadores se esfuerzan por mitigar el riesgo de «alucinaciones» que pueden generar los LLM, optimizando así la precisión y la eficiencia analíticas. Los resultados indican que los LLM pueden reducir sustancialmente los tiempos de procesamiento de las evaluaciones, mejorando así la calidad de la toma de decisiones dentro de las instituciones educativas.

Millan (2025) en su trabajo de investigación "Estudio comparativo de sistemas de recomendación mediante filtrado colaborativo, basado en contenido y propuestas híbridas" tuvo como objetivo comparar el rendimiento de los tres tipos de sistemas de recomendación (filtrado colaborativo, basado en contenido y modelos híbridos), emplearon datos provenientes de Goodreads que incluyó 93,398 libros 34,919 254

interacciones usuario-libro y 2389900 reseñas, los resultados obtenidos son los modelos híbridos mejoran la calidad de la recomendaciones superando los problemas de sobre especialización y escasez de datos, la conclusión fue que los sistemas híbridos combinan eficientemente los enfoques de filtrado colaborativo y basado en contenido, lo que mejora la precisión, la diversidad y la adaptabilidad de las recomendaciones.

(Martínez Sixto et al., 2025) establecieron como objetivo evaluar el desempeño de seis modelos de Lenguaje Grnade (LLMs) dentro de un sistema de Generación Aumentada por Recuperación (RAG) para generar diagramas de clases UML a partir de historias de usuario redactadas en lenguaje natural. El estudio involucro seis LLMs : Gemini- 2.5-Pro, Claude – Sonnet – 4, GPT-4, Llama3.2, estos modelos fueron evaluados en su capacidad para generar diagramas UML a partir de diez historias de usuario, los resultados mostraron que modelos como Claude – Seonnet-4. Gemini-2.5-Pro y GPT-4 obtuvieron un mejor desempeño, el estudio la efectividad del RAG depende en gran medida de la calidad y relevancia de la información contextual recuperada.

## 5.2. Nacional y local

Balarezo et al. (2024) Tuvieron como objetivo diseñar un asistente conversacional basado en arquitectura RAG, para optimizar la búsqueda, recuperación y análisis de información de resoluciones históricas de la CEB- INDECOPI, mejorando la productividad y eficiencia del proceso resolutivo, la población se centró en la resoluciones históricas emitidas por la CEB-INDECOPI, los resultados a los que arribaron son que el diseño optimiza la búsqueda contextual de resoluciones, reduce tiempos de revisión, análisis y redacción, mejora la precisión de respuestas frente a buscadores tradicionales, concluyeron mencionando que el viable, pertinente y beneficiosa la implementación de un asistente inteligente RAG en la CEB

Yatco y Jacha (2024) realizaron la investigación titulada “Modelo de Machine Learnig para predicción de deserción estudiantil” cuyo objetivo fue desarrollar un modelo predictivo utilizando machine learning para prever la deserción estudiantil en Perú, así mismo se basó en datos obtenidos en la encuesta nacional de hogares, así incorporando una amplia gama de variables sociodemográficas para identificar factores asociados a la deserción estudiantil, los resultados que obtuvieron son que el modelo predictivo desarrollado demostró un potencial en la identificación temprana de estudiantes en riesgo de desertar, llegaron a la conclusión de que el modelo machine learning propuesto fu efectivo para predecir la deserción estudiantil permitiendo identificar factores claves, también sugirieron la exploración futura de modelos híbridos y técnicas Deep learning.

Guadalupe y Rodriguez (2025) en su estudio “Modelo predictivo basado en machine learning para la reducción de la deserción estudiantil en las universidades privadas del Perú: Caso universidad privada san Juan Bautista” tuvieron como propósito desarrollar un modelo predictivo basado en machine learning que contribuya en la determinación de estrategias efectivas para la reducción de la deserción estudiantil, la metodología aplicada fue de enfoque cuantitativo orientado a resolver problemas específicos a través de la implementación de un modelo predictivo, el diseño fue preexperimental de corte longitudinal, los resultados que obtuvieron que el modelo predictivo mostro una capacidad efectiva para anticipar la deserción, finalmente concluyeron que los factores personales, académicos y socioeconómicos son determinantes en la deserción, y las estrategias de intervención específicas pueden ser clave para mejorar la retención de estudiantes.

Rodriguez (2023) presenta una metodología cuantitativa, descriptica donde utilizo encuestas a los estudiantes de la Universidad Nacional del Altiplano en la región Puno, La recolección de datos fue mediante censal, su objetivo fue precisar el nivel de relación que existe entre la inteligencia artificial y el rendimiento académico de los estudiantes, los resultados que obtuvo evidencia que la IA es una herramienta eficaz para mejorar el rendimiento académico.

Velasquez (2023) se planteó como objetivo realizar una revisión sistemática de la literatura sobre la inteligencia artificial aplicada al sector educativo para proporcionar una estructura para futuras

investigaciones en ese ámbito, además siguió la propuesta de kitchenham para revisiones sistemáticas de la literatura, los resultados que obtuvo son la aplicación de tutores de inteligencia fueron destacados,

Rodriguez (2023) realiza el abordaje de la relación existente entre inteligencia artificial (IA) y rendimiento académico de los estudiantes de la Universidad Nacional del Altiplano, Puno. Mediante un enfoque cuantitativo y un diseño no experimental descriptivo, se determina que en la investigación se encontró que la inteligencia artificial tiene efecto positivo en el rendimiento académico referidos principalmente a aprendizaje automático, tecnología de código abierto y dispositivos portátiles. La muestra censal tuvo un total de 82 estudiantes, destacando que los hallazgos recogen relaciones significativas en el contexto de la inteligencia artificial y diferentes herramientas tecnológicas, lo que sugiere que la inteligencia artificial como tecnología puede contribuir a mejorar la calidad de la educación en la región.

Fernandez et al. (2025) Se centraron en optimizar y ajustar grandes modelos lingüísticos mediante técnicas de microajuste, utilizando infraestructura informática de alto rendimiento (HPC), como el superordenador Clementina XXI. Tuvieron como objetivo mejorar la eficiencia computacional y el rendimiento específico de tareas en diversos ámbitos, como la seguridad, la biología y la educación. Empleando metodologías avanzadas como LoRA, QLoRA, Adapter Tuning y MoE, se esfuerzan por adaptar los modelos a nuevos escenarios de aplicación con un coste computacional reducido. Los resultados de la investigación abarcan la evaluación de la eficacia de estas técnicas y el establecimiento de repositorios abiertos para fomentar la reproducibilidad de los proyectos, optimizando así de forma integral la utilización de los recursos y reduciendo la duración de la formación.

Rodas (2024) Realizo una investigación titulada "Orientación vocacional y deserción universitaria en una universidad de Lima - 2024" tuvo como objetivo principal explorar la conexión entre la orientación vocacional y la deserción universitaria. Utilizando un enfoque cuantitativo y un diseño no experimental, se analizó una muestra de 103 estudiantes de ingeniería. Los hallazgos mostraron una correlación inversa significativa entre ambas variables: a medida que la orientación vocacional aumenta, la tasa de deserción universitaria disminuye. Este descubrimiento subraya la importancia de ofrecer una orientación vocacional adecuada para ayudar a reducir la deserción estudiantil, destacando que también influyen factores externos, institucionales, académicos y personales en este fenómeno.

Cisneros-Bravo et al. (2023) exploraron cómo la falta de orientación vocacional influye en la deserción universitaria. A través de una metodología mixta, encuestaron a 231 estudiantes de bachillerato, y los hallazgos mostraron que el 36.8% de ellos no recibió ninguna orientación vocacional, mientras que un 87% manifestó su interés en contar con herramientas de orientación. Los resultados subrayaron que la falta de esta orientación es un factor clave en la deserción universitaria, lo que sugiere que es fundamental mejorar estas herramientas en el nivel medio superior para ayudar a prevenir el abandono académico y facilitar una elección vocacional más informada.

Carballo-Mendivil et al. (2025) diseñaron un sistema de alerta temprana orientado a predecir la deserción universitaria desde el momento de la inscripción. Para ello, analizaron información académica, socioeconómica y demográfica de cerca de 40,000 estudiantes pertenecientes a una universidad pública en México. La investigación, de carácter cuantitativo y predictivo, siguió la metodología CRISP-DM y utilizó el algoritmo XGBoost, que obtuvo un valor AUC-ROC de 0.69 y una sensibilidad del 88%. Los hallazgos mostraron que variables como la edad, el promedio del bachillerato y las condiciones económicas y familiares tuvieron un papel determinante en la deserción. Se concluyó que el modelo permitió detectar a los estudiantes con riesgo de abandono antes del inicio del ciclo escolar, lo que posibilitó implementar acciones preventivas y estrategias institucionales enfocadas en mejorar la retención estudiantil.

## VI. MARCO TEÓRICO

### 6.1. Arquitectura Híbrida

Este enfoque combina dos o más métodos, técnicas o arquitecturas distintos para integrar sus respectivas fortalezas y superar sus limitaciones. Por ejemplo, en el campo de los sistemas de recomendación, una arquitectura híbrida integra el filtrado colaborativo con el filtrado basado en el contenido para ofrecer servicios de recomendación más precisos y personalizados. Esta integración tiene como objetivo mejorar la eficiencia y la exactitud de los sistemas, especialmente en situaciones donde un solo enfoque no es suficiente, como en el caso del "cold start" o cuando hay escasez de datos.(Millan, 2025)

Una arquitectura híbrida que combina modelos lingüísticos de gran tamaño con modelos tabulares integra las capacidades de comprensión contextual de los modelos a gran escala con las capacidades analíticas estructuradas que proporcionan los algoritmos tabulares tradicionales. Esta colaboración permite procesar tanto datos no estructurados como estructurados al mismo tiempo, lo que mejora la adaptabilidad y precisión en tareas de predicción o clasificación en áreas específicas, como la medicina, la educación o las finanzas (Zheng et al., 2023).

## 6.2. LoRA (Low-Rank Adaptation)

Según Song et al. (2025); Zhang et al. (2025) se trata de una técnica para ajustar modelos lingüísticos preentrenados a gran escala como los basados en la arquitectura Transformer a tareas específicas sin necesidad de ajustar todos los parámetros del modelo. En lugar de modificar cada uno de los parámetros, LoRA introduce matrices de descomposición de bajo rango en las capas del modelo, lo que reduce considerablemente la cantidad de parámetros que se pueden entrenar. Esto permite hacer ajustes de manera más eficiente en términos de memoria y computación, al mismo tiempo que se mantiene la efectividad del modelo en tareas concretas. LoRA resulta especialmente útil en el caso de modelos muy grandes, como GPT-3, donde realizar un ajuste completo se vuelve poco práctico debido a la enorme cantidad de parámetros que necesitan ser recalibrados.(Gao et al., 2025; Liu et al., 2025)

## 6.3. LLMs (Large Language Models)

Karan y Shekoofeh (2023) lo definen como un modelo de lenguaje grande (LLM), una forma avanzada de inteligencia artificial capaz de comprender y generar lenguaje natural mediante el entrenamiento con vastos conjuntos de datos de texto. Estos modelos sirven como arquitecturas fundamentales versátiles aplicables en diversos campos, como la atención sanitaria, y demuestran un potencial significativo en tareas como el razonamiento clínico, la recuperación de información y la respuesta a preguntas. Sin embargo, es crucial realizar evaluaciones exhaustivas para evitar errores y sesgos.(Negueruela et al., 2024; H. Zhang et al., 2026)

## 6.4. Fine-tuning (ajuste fino)

El ajuste fino, o fine-tuning, es un proceso en el que se reentrena parcialmente un modelo lingüístico de gran escala (LLM) que ya ha sido preentrenado. Su objetivo es adaptar el conocimiento general del modelo a un dominio o tarea específica. Este enfoque mantiene los parámetros esenciales del modelo y los ajusta utilizando un conjunto de datos especializado, lo que mejora su precisión y relevancia en contextos como la medicina o la educación(Li et al., 2023)

## 6.5. Modelos Tabulares

Los modelos tabulares son algoritmos de aprendizaje automático que se especializan en manejar datos estructurados, organizados en tablas con variables bien definidas. Estos modelos son capaces de detectar patrones entre las columnas (características) y las filas (instancias), lo que les permite realizar tareas de predicción y clasificación en situaciones donde la información tiene una estructura relacional clara, como en bases de datos médicas, financieras o educativas (Zavala et al., 2024).

## 6.6. Generación de Rutas Educativas

La creación de rutas educativas es un proceso que se basa en el análisis de datos académicos, personales y vocacionales, con el objetivo de recomendar itinerarios de aprendizaje personalizados para

359 cada estudiante. Al combinar modelos predictivos tabulares con modelos de lenguaje (LLM), se pueden  
360 identificar patrones de rendimiento, intereses y riesgos de deserción, lo que permite diseñar trayectorias  
361 formativas adaptadas al perfil y contexto individual (Cen et al., 2024; Nass et al., 2023)

### 362 6.7. In-context learning

363 El Aprendizaje In-Contexto (ICL) denota la capacidad de los modelos lingüísticos a gran escala  
364 para adquirir nuevas tareas a través de ejemplos de entrada sin necesidad de modificar sus parámetros  
365 internos. Este proceso se basa en mecanismos de atención contextual, lo que permite a los modelos  
366 adaptarse instantáneamente a diversos ámbitos mediante ejemplos o instrucciones, lo que los convierte en  
367 una alternativa flexible al ajuste tradicional. (Kung et al., 2023)

### 368 6.8. Ranqueo de Rutas Educativas

369 La creación de rutas educativas se basa en el análisis de datos académicos, personales y  
370 profesionales, con el objetivo de recomendar programas de aprendizaje personalizados para cada estudiante.  
371 Mediante la integración de modelos predictivos tabulares con modelos lingüísticos (LLM), se pueden  
372 identificar patrones de rendimiento académico, inclinaciones de interés y riesgos de abandono, lo que  
373 permite diseñar trayectorias de desarrollo educativo adaptadas a las características y antecedentes  
374 individuales. (Fernandez et al., 2025; Navarro et al., 2025).

### 375 6.9. Orientación vocacional

376 Según Cisneros-Bravo et al. (2023); Alejandro (2024) mencionan que la orientación vocacional es  
377 un proceso educativo y psicológico diseñado para ayudar a los estudiantes a explorar sus intereses, valores  
378 y habilidades, permitiéndoles así tomar decisiones académicas acordes con sus planes de vida.

379 En la actualidad este proceso integra herramientas tecnológicas e inteligencia artificial para ofrecer  
380 asesoramiento educativo personalizado y mejorar las tasas de retención universitaria. (Flores et al., 2020 p  
381 35).

### 382 6.10. Perfil del estudiante

383 Los perfiles de los estudiantes proporcionan una descripción completa de las habilidades, intereses,  
384 motivaciones, rendimiento académico y capacidades tecnológicas de cada individuo. Esta información es  
385 fundamental para orientar las decisiones educativas y adaptar el proceso de aprendizaje. En los entornos  
386 educativos actuales, se pueden emplear tecnologías de inteligencia artificial, como modelos lingüísticos y  
387 análisis de datos, para crear itinerarios de aprendizaje específicos para cada contexto. (Yupanquin, 2024)

### 388 6.11. Éxito académico y retención estudiantil

389 El éxito académico denota el logro integral de los objetivos de aprendizaje, o el grado en que los  
390 estudiantes alcanzan las metas de aprendizaje establecidas por el sistema educativo. Esto se manifiesta en  
391 un rendimiento académico constante, satisfacción personal y la capacidad sostenida para cursar estudios  
392 universitarios (Aguilar-Reyes et al., 2025).

393 Así mismo la retención estudiantil abarca las estrategias tanto institucionales como personales que  
394 buscan asegurar que los estudiantes continúen hasta completar sus estudios. Ambos aspectos están  
395 influenciados por factores vocacionales, académicos y tecnológicos, y se pueden mejorar utilizando  
396 modelos de inteligencia artificial que ayudan a predecir riesgos y personalizar la intervención educativa  
397 (Moreira et al., 2024; Muñoz et al., 2024).

### 398 6.12. Desempeño académico

399 El desempeño académico es el resultado del proceso de aprendizaje de un estudiante reflejado en  
400 su nivel de rendimiento académico, se mide generalmente mediante calificaciones, evaluaciones,  
401 cumplimiento de objetivos educativos y desarrollo de competencias. (Jardon et al., 2024)

Por otro lado, desde un enfoque integral, el rendimiento académico no se basa únicamente en las habilidades cognitivas del estudiante, sino que también está influenciado por su motivación, la adecuación entre sus intereses y la carrera que ha elegido, así como por las condiciones institucionales que pueden facilitar o complicar su aprendizaje (Escalante López et al., 2023). Además, la literatura reciente hace hincapié en que los factores personales y afectivos como la autoeficacia, las habilidades de gestión del tiempo y la percepción del apoyo institucional son cruciales para el rendimiento educativo y la perseverancia (Rodas, 2024).

### 6.13. Deserción estudiantil

La deserción se refiere al abandono del proceso educativo antes de que se complete. Según Torres-Delgado et al. (2024) la deserción escolar o universitaria es un fenómeno que tiene múltiples causas, donde se entrelazan factores académicos, sociales, familiares y personales que afectan la decisión de dejar los estudios.

### 6.14. Inteligencia artificial

La inteligencia artificial es una rama de la informática que se centra en el diseño, desarrollo y aplicación de sistemas que pueden llevar a cabo tareas que, hasta hace poco, necesitaban de la inteligencia humana. Estas tareas abarcan desde el razonamiento lógico y el aprendizaje a partir de datos, hasta la percepción del entorno, la comprensión del lenguaje natural, la toma de decisiones y la resolución de problema (Ramos-Rivera et al., 2025; Sancho et al., 2020)

## VII. METODOLOGÍA

### 7.1 Lugar de Estudio

La investigación se desarrollará en la Universidad Nacional del Altiplano Puno (UNAP-Puno), ubicada en la ciudad de Puno, provincia de Puno, región Puno, Perú, a una altitud aproximada de 3 827 m s. n. m. Sus coordenadas geográficas son aproximadamente 15°50'24" S, 70°01'19" S.



### 7.2 Población y tamaño de muestra

#### 7.2.1 Población

La población de estudio está conformada por los 12 000 postulantes a la Universidad Nacional del Altiplano Puno (UNAP-Puno) en los procesos de admisión comprendidos entre 2022-I y 2025-II, para los cuales se cuenta con información académica y sociodemográfica registrada en la Oficina de Admisión. De manera equivalente, se consideran los mismos 12 000 estudiantes como parte de la población de egresados de educación secundaria de la región Puno, cuyos datos se encuentran en los registros de la DRE-UGEL Puno.

### 7.2.2 Muestra

Dado que se trabajará con la totalidad de los registros disponibles y emparejados entre la Oficina de Admisión de la UNAP-Puno y la DRE-UGEL Puno, la muestra coincide con la población, por lo que:

$$N = n = 12\ 000.$$

En consecuencia, no se aplica fórmula de cálculo muestral, pues el estudio adopta un diseño censal respecto de los postulantes a la UNAP-Puno en el periodo 2022-I a 2025-II.

## 7.3 Descripción detallada de los métodos, uso de materiales, equipos o insumos

### 7.3.1 Diseño de muestreo

### 7.3.2 Descripción detallada del uso de materiales, equipos, insumos, entre otros

Para el desarrollo del estudio se emplea un conjunto de materiales, equipos e insumos de carácter tecnológico y documental, orientados al procesamiento, modelado y análisis espacial de los datos de admisión de la UNAP-Puno. Los materiales principales corresponden a software de código abierto y a librerías especializadas de ciencia de datos y aprendizaje automático, los cuales permiten ejecutar las tareas de limpieza, transformación, modelado y visualización sin incurrir en costos de licencias comerciales, garantizando la reproducibilidad de los experimentos y la sostenibilidad económica del proyecto.

En cuanto a los equipos, se utiliza una estación de trabajo con capacidad de cómputo suficiente para el entrenamiento de los modelos tabulares y de lenguaje, complementada con servicios de cómputo en la nube cuando se requiere mayor capacidad de procesamiento. Los insumos están constituidos por los conjuntos de datos institucionales, conformados por los padrones de admisión de la UNAP-Puno del periodo 2022-I a 2025-II, los registros de egresados de educación secundaria de la DRE-UGEL Puno, los catálogos de carreras profesionales y las bases georreferenciadas del INEI, así como los instrumentos de consentimiento institucional y los protocolos de anonimización que aseguran el tratamiento ético de la información. El detalle de cada herramienta y recurso se presenta en los apartados siguientes.

### 7.3.3 Descripción de variables a ser analizados en el objetivo específico

Para el procesamiento y modelado de datos, se utilizará exclusivamente software de código abierto (Open Source). El lenguaje de programación base será Python 3.10 bajo licencia PSF. Las librerías de manipulación de datos (Pandas, NumPy) y de aprendizaje automático (Scikit-learn, XGBoost, Transformers de HuggingFace) operan bajo licencias BSD y Apache 2.0, las cuales permiten su uso académico y profesional sin costo de adquisición de licencias comerciales. El entrenamiento se realizará en entornos gratuitos/abiertos como Google Colab (en su versión estándar) o servidores locales, garantizando la sostenibilidad económica del proyecto.

A continuación, se detallan las herramientas tecnológicas y recursos adicionales:

## Software y bibliotecas:

- Python 3.10+: Lenguaje principal para procesamiento de datos y desarrollo de modelos.
- Pandas y NumPy: Para limpieza, transformación y análisis de datos tabulares.
- Scikit-learn: Para entrenamiento de modelos de clasificación base y validación.
- XGBoost, LightGBM y Random Forest: Algoritmos tabulares para estimación de éxito académico.
- Transformers (Hugging Face): Para el ajuste fino (fine-tuning) del modelo de lenguaje.
- LoRA (Low-Rank Adaptation): Técnica utilizada para adaptar el LLM a tareas específicas.
- MLflow y DVC: Para la trazabilidad de experimentos, control de versiones y reproducibilidad.
- Jupyter Notebook: Entorno de desarrollo interactivo.
- Matplotlib y Seaborn: Para la visualización de datos.

## Equipos:

- Computadora personal con al menos 16 GB de RAM, procesador Intel i7 o superior y tarjeta gráfica (GPU) compatible con CUDA para entrenamiento de modelos.
- Acceso a servidores de cómputo en la nube (como Google Colab, Paperspace o Hugging Face Hub) en caso de requerir mayor capacidad de procesamiento.
- Insumos y datos:
- Padrones de admisión UNAP (2022-I a 2025-II).
- Registros de egresados de secundaria de UGEL/DRE Puno.
- Catálogos de carreras profesionales, perfiles de ingreso y egreso.
- Ubigeo del INEI y clasificación rural y urbana.
- Instrumentos de consentimiento institucional y protocolos de anonimización de datos.

### 7.3.4 Aplicación de prueba estadística inferencial

Para la validación de las hipótesis planteadas, se aplicarán pruebas de significancia estadística y métricas de rendimiento técnico, organizadas según los objetivos específicos:

#### A. Validación del Modelo Tabular (Clasificación)

Para verificar si el modelo XGBoost alcanza la precisión esperada ( $H1: \geq 85\%$ ), se utilizará la técnica de validación cruzada (K-fold cross-validation). La métrica principal de desempeño será el F1-Score, que equilibra la precisión y la exhaustividad:

$$F1 = 2 \times \frac{\text{Presicioón} \times \text{Exhaustividad}}{\text{Prescision} + \text{Exhaustividad}}$$

508 Asimismo, se calculará el área bajo la curva característica operativa del receptor (AUC-  
509 ROC) para medir la capacidad de discriminación del modelo entre postulantes aptos y no  
510 aptos.

#### 511 B. Evaluación del Modelo de Lenguaje

512 Para evaluar la coherencia de las rutas educativas generadas (H3:  $\geq 80\%$ ), se emplearán  
513 métricas de Procesamiento de Lenguaje Natural (PLN). Se utilizará ROUGE-L para medir  
514 la coincidencia de secuencias más largas entre la salida del LLM y la ruta de referencia:  
515

$$516 \text{ ROUGE} - L = \frac{(1+\beta^2)R_{lcs}P_{lcs}}{R_{lcs}+\beta^2P_{lcs}}$$

517  
518 Complementariamente, se aplicará BERTScore para capturar la similitud semántica  
519 mediante embeddings contextuales, superando las limitaciones de la comparación exacta  
520 de palabras.

#### 521 C. Prueba de Hipótesis Híbrida

522 Para comprobar si la arquitectura híbrida supera en un 10% a los modelos individuales  
523 (H4), se aplicará la Prueba t de Student para muestras relacionadas (si los datos siguen una  
524 distribución normal) o la Prueba de Wilcoxon. El nivel de significancia se establece en  $\alpha$   
525 = 0.05. Se buscará rechazar la hipótesis nula ( $H_0$ ) que asuma que no hay diferencia  
526 significativa entre el modelo CareER-GPT y los modelos base.

#### 527 D. Variables de Estudio

528 Las variables involucradas en estos procesos se resumen a continuación:

- 529 • Independiente: Arquitectura híbrida CareER-GPT (LLM ajustado con LoRA y  
530 XGBoost).
- 531 • Dependientes: Precisión predictiva (AUC, F1), Calidad textual (ROUGE,  
532 BERTScore) y Equidad algorítmica (medida por la disparidad de resultados entre  
533 zonas rurales y urbanas).
- 534 • Intervenientes: Calidad del dataset histórico (2022-I a 2025-II) y capacidad  
535 computacional de la GPU.

### 13 536 7.4 Tabla de recolección de datos por objetivos específicos

537 Para garantizar la consecución de los objetivos planteados, se ha diseñado una matriz técnica que  
538 vincula cada propósito específico con su procedimiento de gestión de datos, las herramientas tecnológicas  
539 requeridas y el producto entregable.

| Objetivo Específico                                | Acción de Gestión y Procedimiento | Descripción Técnica Detallada (Paso a Paso)                                          | Herramientas y Entornos de Trabajo | Resultado Técnico Esperado         |
|----------------------------------------------------|-----------------------------------|--------------------------------------------------------------------------------------|------------------------------------|------------------------------------|
| O1: Entrenar y evaluar un modelo tabular (XGBoost) | Extracción y Curación de          | 1. Ingesta: Conexión a bases de datos de Admisión UNAP y DRE Puno mediante consultas | Python 3.11<br>Librería Pandas     | Matriz de confusión y métrica AUC- |

|                                                                                      |                                          |                                                                                                                                                                                                                                                                                                                                                                                                                                                       |                                                                                                          |                                                                     |
|--------------------------------------------------------------------------------------|------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|
| para el ranqueo de probabilidades.                                                   | Datos Estructurados                      | <p>SQL y la librería Pandas.</p> <p>2. Preprocesamiento: Tratamiento de datos perdidos e imputación estadística de valores faltantes.</p> <p>3. Ingeniería de Características: Creación de variables de brecha educativa y normalización de notas mediante Z-score.</p> <p>4. Validación: División del conjunto de datos en 70 % para entrenamiento, 15 % para prueba y 15 % para validación, con ajuste de hiperparámetros.</p>                      | <p>Librería Scikit-learn</p> <p>Motor XGBoost</p>                                                        | ROC superior a 0.85.                                                |
| O2: Preparar y transformar el conjunto de datos en pares de instrucción y respuesta. | Ingeniería de Prompts y Serialización    | <p>1. Mapeo Semántico: Traducción de variables numéricas a descriptores verbales (Ejemplo: Promedio 17 equivale a "Alto desempeño").</p> <p>2. Construcción de Prompts: Diseño de pares de instrucción y respuesta para guiar el aprendizaje del modelo.</p> <p>3. Aumento de Datos: Generación de variantes textuales para evitar el sobreajuste.</p> <p>4. Exportación: Validación de integridad en archivos JSONL compatibles con HuggingFace.</p> | <p>Scripts en Python</p> <p>Formato JSONL</p> <p>Técnicas de Procesamiento de Lenguaje Natural (PLN)</p> | Conjunto de datos de entrenamiento CareER-Dataset con 12 000 pares. |
| O3: Ajustar un LLM mediante LoRA para la generación de rutas.                        | Optimización de Parámetros de Bajo Rango | 1. Configuración PEFT: Definición de parámetros de LoRA (donde r es 16 y alpha es                                                                                                                                                                                                                                                                                                                                                                     | HuggingFace PEFT                                                                                         | Punto de control del modelo (checkpoint) optimizado y funcional.    |

|                                                               |                                             |                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |                                                                           |                                                                             |
|---------------------------------------------------------------|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------|-----------------------------------------------------------------------------|
|                                                               |                                             | <p>32) en módulos de atención.</p> <p>2. Cuantización: Implementación de QLoRA en 4 bits para reducir el consumo de memoria de video.</p> <p>3. Entrenamiento Supervisado: Ciclos de entrenamiento monitoreando la función de pérdida en tiempo real.</p> <p>4. Fusión de Pesos: Integración de los adaptadores LoRA al modelo base para una inferencia rápida.</p>                                                                                                         | <p>PyTorch</p> <p>NVIDIA CUDA (GPU T4 o A100)</p>                         |                                                                             |
| O4: Integrar ambos modelos y validar su eficacia comparativa. | Orquestación de la Arquitectura y Auditoría | <p>1. Inferencia Híbrida: El modelo tabular envía el puntaje de probabilidad como contexto enriquecido al modelo de lenguaje.</p> <p>2. Cálculo de Métricas: Evaluación de ranking con NDCG y calidad textual con ROUGE y BERTScore.</p> <p>3. Pruebas de Sesgo: Evaluación de equidad para asegurar que el modelo no discrimine por zona rural o urbana.</p> <p>4. Control de Versiones: Registro del modelo final en repositorio institucional para reproducibilidad.</p> | <p>Plataforma MLflow</p> <p>Control DVC y Git</p> <p>API de BERTScore</p> | Sistema CareER-GPT validado con mejora superior al 10 % respecto a la base. |

540

541

4

542

## VIII. CRONOGRAMA DE ACTIVIDADES

| ACTIVIDADES | MES - 2024 |     |     |     |     |     |     |
|-------------|------------|-----|-----|-----|-----|-----|-----|
|             | OCT        | NOV | DIC | ENE | FEB | MAR | ABR |

|                                          |   |   |   |   |   |   |   |
|------------------------------------------|---|---|---|---|---|---|---|
| Elaboración del proyecto                 | X |   |   |   |   |   |   |
| Revisión y aprobación del proyecto       | X |   |   |   |   |   |   |
| Recopilación y Preprocesamiento de datos |   | X |   |   |   |   |   |
| Desarrollo de Modelos Tabulares          |   |   | X |   |   |   |   |
| Fine-Tuning de LLM con LoRA              |   |   | X |   |   |   |   |
| Evaluación de Modelo (Métricas)          |   |   | X |   |   |   |   |
| Análisis de resultados                   |   |   |   | X |   |   |   |
| Redacción de Informa y documentación     |   |   |   |   | x |   |   |
| Presentación                             |   |   |   |   | x |   |   |
| Sustentación                             |   |   |   |   |   | x | x |

543

544 **IX. PRESUPUESTO**

| Nº | Descripción                              | Unidad de medida | Costo Unitario | Cantidad | Costo Total (S/.) |
|----|------------------------------------------|------------------|----------------|----------|-------------------|
|    |                                          |                  | (S/.)          |          |                   |
| 1  | Laptop                                   | Unidad           | 2500.00        | 1        | S/. 2500.00       |
| 2  | GPU Cloud pro                            | Mes              | 200.00         | 4        | S/. 800.00        |
| 3  | Almacenamiento Nube (Google)             | Mes              | 60.00          | 4        | S/. 240.00        |
| 4  | GPU dedicada en la nube (AWS, GCP, etc.) | Mes              | 200.00         | 4        | S/. 800.00        |
| 5  | Material de oficina                      | Paquete          | 120.00         | 1        | S/. 120.00        |
| 6  | Impresora                                | Unidad           | 700.00         | 1        | S/. 700.00        |
| 7  | Viáticos y movilidad                     | Servicio         | 150.00         | 1        | S/. 150.00        |
| 8  | Impresiones hoja                         | Unidad           | 0.08           | 400      | S/. 32.00         |
| 9  | Imprevistos(otros)                       | Unidad           | 200.00         | 1        | S/. 200.00        |
| 10 | USB                                      | Unidad           | 35.00          | 1        | S/. 35.00         |
| 11 | Servidores adicionales                   | Mes              | 100.00         | 4        | S/. 400.00        |
|    | TOTAL                                    |                  |                |          | S/. 5977.00       |

545

546 **X. BIBLIOGRAFÍA**

- 547 Aguilar-Reyes, J. E., Mejía-Peñañiel, E. F., Morocho-Barrionuevo, T. P., y Velasco-Castelo, G.-M. (2025).  
 548 Estudio del rendimiento académico mediante la comparación de modelos de regresión y árboles de  
 549 clasificación. *Telos: Revista de Estudios Interdisciplinarios en Ciencias Sociales*, 27(1), 94-115.  
 550 <https://doi.org/10.36390/telos271.08>
- 551 Alejandro, S. Y. (2024). Orientación Vocacional y Profesional: La Inteligencia Artificial y su impacto en  
 552 la Educación. *Revista Cientific*, 9(34), 285-300. <https://doi.org/10.29394/scientific.issn.2542-2987.2024.9.34.13.285-300>
- 554 Armando, J., Caranqui, L., y Riofrío, D. (2023). *URKU: Adaptación de LLaMA 2 para la generación de*  
 555 *texto en Kichwa usando técnicas de Low-Rank Adaptation (LoRA)* [Tesis de maestría, Universidad  
 556 San Francisco de Quito USFQ]. <http://bit.ly/COPETheses>.
- 557 Balarezo, M., Pia, M., Hurtado, A., Alfredo, W., Churata, G., Francis, H., Atiquipa, S., Franklin, E., Felix,  
 558 T., y Erick, R. (2024). *Diseño de un Asistente Inteligente RAG para la Comisión de Eliminación de*

- 559 *Barreras Burocráticas de INDECOPI-2024* [Tesis de Maestria, Universidad Peruana de Ciencias  
560 Aplicadas]. <http://hdl.handle.net/10757/684330>
- 561 Carballo-Mendivil, B., Arellano-González, A., Ríos-Vázquez, N. J., y Lizardi-Duarte, M. del P. (2025).  
562 Predicting Student Dropout from Day One: XGBoost-Based Early Warning System Using Pre-  
563 Enrollment Data. *Applied Sciences (Switzerland)*, 15(16). <https://doi.org/10.3390/app15169202>
- 564 Castejon, F. (2025). *SoroIA: Diseño e implementacion de un sistema conversacional basado en modelos*  
565 *grandes de Lenguaje para el Museo Sorolla* [Tesis Master en Ciencia de Datos, Universidad  
566 Politecnica de Madrid]. [https://oa.upm.es/90917/1/TFM\\_FEDERICO\\_CASTEJON\\_LOZANO.pdf](https://oa.upm.es/90917/1/TFM_FEDERICO_CASTEJON_LOZANO.pdf)
- 567 Cen, C., Luo, G., Tian, Y., Fu, B., Chen, Y., Huang, S., Jiang, T., y Huang, G. (2024). Enhancing the  
568 dissemination of Cantonese Opera among youth via Bilibili: a study on intangible cultural heritage  
569 transmission. *Humanities and Social Sciences Communications*, 11(1).  
570 <https://doi.org/10.1057/s41599-024-03537-w>
- 571 Cisneros-Bravo, B. E., Rodríguez-Aguilar, R. M., Niño-Membrillo, Y. E., y Cuevas-Rasgado, A. D. (2023).  
572 Falta de orientación vocacional como factor en la deserción universitaria. Caso de estudio: zona  
573 Oriente del Estado de México. *RIDE Revista Iberoamericana para la Investigación y el Desarrollo*  
574 *Educativo*, 14(27). <https://doi.org/10.23913/ride.v14i27.1715>
- 575 Escalante López, J. I., Medina Valderrama, C. J., y Vásquez Muñoz, A. (2023). La deserción universitaria:  
576 un problema no resuelto en el Perú. *Hacedor - AIAPÆC*, 7(1), 60-72.  
577 <https://doi.org/10.26495/rch.v7i1.2421>
- 578 Fang, X., Xu, W., Tan, F. A., Zhang, J., Hu, Z., Qi, Y., Nickleach, S., Socolinsky, D., Sengamedu, S., y  
579 Faloutsos, C. (2024). Large Language Models(LLMs) on Tabular Data: Prediction, Generation, and  
580 Understanding -- A Survey. *Transactions on Machine Learning Research*, 2, 122-134.  
581 <http://arxiv.org/abs/2402.17944>
- 582 Fernandez, J. M., Petrocelli, D., Matuk, R., Lanson, D., Zamudio, E., Cagnina, L., Gil Costa, V., y  
583 Errecalde, M. (2025). *Fine-tuning y adaptación de Modelos de Lenguaje abiertos en Infraestructura*  
584 *HPC para aplicaciones de dominio específico*. <https://doi.org/10915/183892>
- 585 Flores Meléndez, M., Góngora Cortés, J. J., López Cabrera, M. V., y Eraña Rojas, I. E. (2020). The «call»  
586 of medicine. Use of new mentoring models for vocational orientation. *Educacion Medica*, 21(2), 145-  
587 148. <https://doi.org/10.1016/j.edumed.2018.11.008>
- 588 Gao, D., Chen, S., Yang, Z., Yang, L., Gao, H., Wu, M., Yu, S., Xuan, Q., Zhang, W., Yang, L., y Cai, X.  
589 (2025). MLoRA+: Transformer-fusion mixture-of-LoRA network for multi-domain click-through  
590 rate prediction. *Expert Systems with Applications*, 297, 100-110.  
591 <https://doi.org/10.1016/j.eswa.2025.129486>
- 592 Garcia, G., y Serradilla, F. (2021). *Modelos de Transformers para la Clasificación de Texto* [Tesis de  
593 Mestria]. Universidad Politécnica de Madrid.
- 594 Guadalupe, V., y Rodriguez, C. (2025). *Modelo predictivo basado en Machine Learning para la reduccion*  
595 *de la desercion estudiantil en las universidades privadas del Peru: Caso universidad Privada San*  
596 *Juan Bautista* [Tesis para optar el grado de Doctor en Ingenieria de Sistemas]. Universidad Nacional  
597 Federico Villareal.
- 598 Hernández Sampieri, R., Fernández Collado, C., María del Pilar Baptista Lucio, D., y Méndez Valencia  
599 Christian Paulina Mendoza Torres, S. (2016). *Metodologia de la Investigacion 6a Edicion*. Printed in  
600 Mexico.
- 601 Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., y Chen, W. (2021). LoRA: Low-  
602 Rank Adaptation of Large Language Models. *Computer Science*. <https://doi.org/10.48550/arXiv>.

- 603 Jardon, M., Granizo, J., Yaselga, W., y Cocha, M. (2024). Impacto de los asistentes virtuales de inteligencia  
604 artificial en el rendimiento académico de estudiantes universitarios. *Revista Social Fronteriza*;, 4.  
605 [https://doi.org/10.59814/resofro.2024.4\(4\)e338](https://doi.org/10.59814/resofro.2024.4(4)e338)
- 606 Karan Singhal, y Shekoofeh, A. (2023). Large language models encode clinical knowledge. *Nature*, 6, 171-  
607 179. <https://doi.org/10.1038/s41586-023-06291-2>
- 608 Kung, T. H., Cheatham, M., Medenilla, A., Sillos, C., De Leon, L., Elepaño, C., Madriaga, M., Aggabao,  
609 R., Diaz-Candido, G., Maningo, J., y Tseng, V. (2023). Performance of ChatGPT on USMLE:  
610 Potential for AI-assisted medical education using large language models. *PLOS Digital Health*, 2(2  
611 February). <https://doi.org/10.1371/journal.pdig.0000198>
- 612 Li, Y., Li, Z., Zhang, K., Dan, R., Jiang, S., y Zhang, Y. (2023). ChatDoctor: A Medical Chat Model Fine-  
613 Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge. *Cureus*.  
614 <https://doi.org/10.7759/cureus.40895>
- 615 Liu, Z., Liu, Z., Feng, R., Feng, P., Chu, J., y Peng, X. (2025). LoRA-TCN: A pre-trained/fine-tuning  
616 learning paradigm for drift adaptation. *Sensors and Actuators B: Chemical*, 446.  
617 <https://doi.org/10.1016/j.snb.2025.138644>
- 618 Martínez Sixto, L., Fernández y Fernández, C. A., y Millán Hernández, C. E. (2025). Comparación del  
619 desempeño de LLMs en la generación de diagramas de clases UML mediante un sistema RAG.  
620 *Revista de Investigación en Tecnologías de la Información*, 13(31), 64-79.  
621 <https://doi.org/10.36825/riti.13.31.007>
- 622 Mena, S. (2023). *Usos y aplicaciones de modelos de lenguaje masivos en español* [Tesis para optar el grado  
623 de Maestro]. Universidad San Francisco de Quito USFQ.
- 624 Millan, M. (2025). *Estudio comparativo de sistemas de recomendación mediante filtrado colaborativo,*  
625 *basado en contenido y propuestas híbridas* [Tesis Maestría, Universidad Loyola Andalucía].  
626 [https://repositorio.uloyola.es/bitstream/handle/20.500.12412/6735/TFM%20Mar%C3%ADa%20Mil](https://repositorio.uloyola.es/bitstream/handle/20.500.12412/6735/TFM%20Mar%C3%ADa%20Mill%C3%A1n.pdf?sequence=1&isAllowed=y)  
627 [l%C3%A1n.pdf?sequence=1&isAllowed=y](https://repositorio.uloyola.es/bitstream/handle/20.500.12412/6735/TFM%20Mar%C3%ADa%20Mill%C3%A1n.pdf?sequence=1&isAllowed=y)
- 628 Moreira, S., Alfredo, P., Montenegro, Z., Fernando, D., Ecuador, P. •, y Ecuador, P. •. (2024). Técnicas de  
629 machine Learning para predecir la deserción estudiantil universitaria: Una revisión sistemática de la  
630 literatura Machine learning techniques to predict university student dropout: A systematic review of  
631 the literature. *Revista Científica Multidisciplinar*. <https://orcid.org/0000-0003-2583->
- 632 Muñoz Piloza, A. G., Villalva Piloza, A. M., Medina Castro, A. R., y Piloza Mendoza, J. J. (2024). Factores  
633 Determinantes en el Éxito del Proceso de Enseñanza-Aprendizaje. *Revista Científica*, 9(33), 45-63.  
634 <https://doi.org/10.29394/scientific.issn.2542-2987.2024.9.33.2.45-63>
- 635 Nass, O., Skuliabina, O., Bapiyev, I., Dnekeshev, A., Bekenova, S., y Bekenova, A. (2023). Blended  
636 learning as a promising direction of informatization of higher education. *E3S Web of Conferences*,  
637 389. <https://doi.org/10.1051/e3sconf/202338908003>
- 638 Navarro Forero, C. A., Hernández, M. A., y Viloria, K. T. (2025, septiembre 8). *Nuevas rutas de*  
639 *aprendizaje adaptación de contenidos académicos a formatos audiovisuales para mejorar la*  
640 *preparación de los estudiantes*. <https://doi.org/10.26507/paper.4223>
- 641 Negueruela, I., Duque, R., y Uriel, R. (2024). *Análisis y evaluación de LLMs con técnicas RAG para el*  
642 *desarrollo y despliegue de un asistente virtual*.
- 643 Ramos-Rivera, R. E., Santana Mancilla, P. C., Garcia-Mancilla, J., y Gaytán-Lugo, L. S. (2025). Modelos  
644 de lenguaje en educación: Inteligencia Artificial Generativa para optimizar el análisis del desempeño  
645 docente. *Revista Científica en Educación de la Universidad Autónoma de Nueva*, 1(2), 70-81.  
646 <https://doi.org/10.29105/innoacad.v1i2.36>

- 647 Rodas, A. (2024). *Orientación vocacional y deserción universitaria en una universidad de Lima - 2024*.  
648 Universidad Cesar Vallejo.
- 649 Rodriguez, Y. (2023). *Inteligencia Artificial y Rendimiento Academico de los estudiantes de educacion*  
650 *superior en la region Puno, 2022* [Tesis para optar el grado de Master en docencia universitaria,  
651 Universidad Alas Peruanas]. <https://orcid.org/0000-0002-1385-3139>
- 652 Sancho Escrivá, J. V., Fanjul Peyró, C., De la Iglesia Vayá, M., Montell, J. A., y Escartí Fabra, M. J. (2020).  
653 Aplicación de la Inteligencia Artificial con Procesamiento del Lenguaje Natural para textos de  
654 investigación cualitativa en la relación médico-paciente con enfermedad mental mediante el uso de  
655 tecnologías móviles. *Revista de Comunicación y Salud*, 10(1), 19-41.  
656 [https://doi.org/10.35669/rcys.2020.10\(1\).19-41](https://doi.org/10.35669/rcys.2020.10(1).19-41)
- 657 Song, Y., Lv, C., Zhu, K., y Qiu, X. (2025). LoRA fine-tuning of Llama3 large model for intelligent fishery  
658 field. *Discover Computing*, 28(1). <https://doi.org/10.1007/s10791-025-09663-6>
- 659 Torres-Delgado, G., Ramos-Pulido, S., y Hernández-Gress, N. (2024). Satisfaction with Research-Based  
660 Learning and Academic Performance by Big Data Analysis †. *Engineering Proceedings*, 74(1).  
661 <https://doi.org/10.3390/engproc2024074074>
- 662 Velasquez, S. (2023). *La inteligencia artificial aplicada al sector educativo: una revisión sistemática de la*  
663 *literatura*. <https://orcid.org/0000-0003-3520-5076>
- 664 Yatco, W., y Jacha, J. (2024). *Modelo machine learning para predicción de deserción estudiantil* [Tesis de  
665 Segunda Especialidad]. Universidad Peruana Union.
- 666 Yupanquin, L. A. (2024). *Perfil del egresado y la formacion prfocional en estudiantes del ultimo año de*  
667 *arquitectura de la universidad femenina del Sagrado Corazon, 2020* [Tesis de Maestria, Universidad  
668 Nacional de Educacion Enrique Guzman y Valle].  
669 [https://repositorio.une.edu.pe/server/api/core/bitstreams/0a198466-0baf-4299-897b-](https://repositorio.une.edu.pe/server/api/core/bitstreams/0a198466-0baf-4299-897b-90a22a49c958/content)  
670 [90a22a49c958/content](https://repositorio.une.edu.pe/server/api/core/bitstreams/0a198466-0baf-4299-897b-90a22a49c958/content)
- 671 Zavala Guirado, M. A., González Castro, I., Tapia Ruelas, C. S., Cota Valenzuela, L. V., y Durón Ramos,  
672 M. F. (2024). Propiedades psicométricas de una escala para medir la práctica docente universitaria en  
673 la modalidad híbrida. *RIDE Revista Iberoamericana para la Investigación y el Desarrollo Educativo*,  
674 14(28). <https://doi.org/10.23913/ride.v14i28.1878>
- 675 Zhang, H., Li, Z., y Liu, J. (2026). SceneLLM: Implicit language reasoning in LLM for dynamic scene  
676 graph generation. *Pattern Recognition*, 170. <https://doi.org/10.1016/j.patcog.2025.111992>
- 677 Zhang, J. C., Xiong, Y. J., Xia, C. M., Zhu, D. H., y Zhan, H. J. (2025). LoRA2: Multi-scale low-rank  
678 approximations for fine-tuning large language models. *Neurocomputing*, 650.  
679 <https://doi.org/10.1016/j.neucom.2025.130859>
- 680 Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P.,  
681 Zhang, H., Gonzalez, J. E., y Stoica, I. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot*  
682 *Arena*. <http://arxiv.org/abs/2306.05685>

683

684 **XI. ANEXO**

## 685 1. Cuadro de matriz de consistencia

686

687

688

**TITULO:** CareER-GPT: Arquitectura Híbrida con LoRA sobre LLMs y Modelos Tabulares para la Generación y Ranqueo de Rutas Educativas en Postulantes de la Región de Puno

| PROBLEMA                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | HIPÓTESIS                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | OBJETIVOS                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | VARIABLES                                                                                                                                                                                                                                                                                           | DIMENSIONES E INDICADORES                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | METODOLOGÍA TÉCNICAS E INSTRUMENTOS                                                                                                                                                                                                                                                                                                                                                                                                                                                |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p><b>Problema Principal:</b></p> <p>¿En qué medida una arquitectura híbrida de IA que combine modelos tabulares y LLMs con LoRA puede optimizar la generación y ranqueo de rutas educativas personalizadas para postulantes universitarios de Puno?</p> <p><b>Problemas Específicos:</b></p> <p><b>P1.-</b> ¿Qué variables académicas, demográficas y socioeducativas predicen mejor la probabilidad de éxito académico por carrera?</p> <p><b>P2.-</b> ¿Cómo transformar los datos de postulantes en entradas textuales útiles para el</p> | <p><b>Hipótesis General:</b></p> <p>La arquitectura híbrida CareER-GPT, basada en LoRA sobre LLMs y modelos tabulares, genera y rankea rutas educativas personalizadas con una precisión significativamente alta para los postulantes de la región de Puno</p> <p><b>Hipótesis Específicas:</b></p> <p><b>H1.-</b> El modelo tabular XGBoost clasifica con al menos un 85% de precisión la probabilidad de éxito por carrera.</p> <p><b>H2.-</b> La transformación del conjunto de datos de postulantes en pares prompt-respuesta de permite generar un corpus sintético representativo,</p> | <p><b>Objetivo General:</b></p> <p>Desarrollar y validar la arquitectura híbrida CareER-GPT, basada en LoRA sobre LLMs y modelos tabulares, para la generación y ranqueo de rutas educativas personalizadas en postulantes de la región de Puno.</p> <p><b>Objetivos Específicos:</b></p> <p><b>O1:</b> Entrenar y evaluar un modelo tabular (XGBoost) para el ranqueo de probabilidades de éxito por carrera.</p> <p><b>O2.</b> Preparar y transformar el dataset de 12,000 postulantes en pares prompt-respuesta para el entrenamiento del modelo de lenguaje.</p> <p><b>O3:</b> Ajustar un LLM mediante LoRA para la generación automática de</p> | <p><b>Variables de la Investigación.</b></p> <p><b>Variable Independiente</b></p> <p>Arquitectura híbrida basada en modelos tabulares y modelos de lenguaje ajustados con LoRA. (CareER-GPT)</p> <p><b>Variable dependiente</b></p> <p>Precisión en la generación y ranqueo de rutas educativas</p> | <p><b>Para la Variable Independiente</b></p> <ul style="list-style-type: none"> <li>• Componente tabular (XGBoost)</li> <li>• Componente lingüístico (LLM ajustado con LoRA)</li> <li>• Integración híbrida de ambos modelos.</li> </ul> <p><b>Indicadores:</b></p> <ul style="list-style-type: none"> <li>- Precisión del modelo tabular (AUC-ROC, F1-Score)</li> <li>- Coherencia y fidelidad textual (ROUGE, BERTScore)</li> <li>- Incremento porcentual del rendimiento híbrido (&gt;10%)</li> <li>- Nivel de personalización en las recomendaciones</li> <li>- Nivel de satisfacción del usuario (escala Likert 1-5)</li> </ul> <p><b>Para la variable dependiente</b></p> <ul style="list-style-type: none"> <li>• Exactitud predictiva</li> <li>• Calidad y coherencia textual</li> <li>• Personalización y adecuación al perfil del usuario</li> <li>• Desempeño comparativo entre modelos</li> </ul> | <p><b>Enfoque:</b></p> <p>Cuantitativo</p> <p><b>Tipo: Aplicada</b></p> <p><b>Diseño de investigación</b></p> <p>Preexperimental</p> <p><b>La Población (N) y Muestra (n):</b></p> <p><b>La Población:</b></p> <p>Postulantes a la Universidad Nacional del Altiplano – periodos 2022-I a 2025-II y egresados de secundaria de Puno</p> <p><b>La Muestra:</b></p> <p>Subconjunto intencional de postulantes y egresados seleccionados por criterios académicos y demográficos.</p> |

|                                                                                                                                                                                                                                                     |                                                                                                                                                                                                                                                                                                                                                                           |                                                                                                                                                   |                                                        |                                                                                                                                                                                                                                                                                                                                                                                                                                  |                                                                                                                                                                                                                                                                                                                                                                                                                                |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>entrenamiento del LLM?</p> <p><b>P3:</b> ¿Qué efectividad tiene el ajuste fino con LoRA para generar rutas educativas relevantes?</p> <p><b>P4:</b> ¿Cuál es el desempeño de la arquitectura híbrida comparada con los modelos individuales?</p> | <p>coherente y balanceado del perfil académico y vocacional.</p> <p><b>H3:</b> El fine-tuning con LoRA permite al LLM generar rutas educativas con coherencia contextual superior al 80%.</p> <p><b>H4:</b> La integración híbrida supera el rendimiento de cada modelo por separado en al menos un 10% en métricas combinadas de clasificación, ranking y fidelidad.</p> | <p>rutas educativas contextualizadas</p> <p><b>O4</b> Integrar ambos modelos en una arquitectura unificada y validar su eficacia comparativa.</p> | <p>personalizadas para postulantes universitarios.</p> | <p><b>Indicadores:</b> Porcentaje de acierto del modelo (<math>\geq 85\%</math>)</p> <ul style="list-style-type: none"> <li>- Coherencia contextual de las rutas generadas (<math>\geq 80\%</math>)</li> <li>- Métricas de ranking (NDCG@5, NDCG@10, MRR)</li> <li>- Diferencia porcentual de mejora del modelo híbrido (<math>\geq 10\%</math>)</li> <li>- Nivel de satisfacción del usuario (<math>\geq 4/5</math>)</li> </ul> | <p><b>Técnicas</b></p> <p><b>Instrumentos:</b> –</p> <p>Recolección de datos académicos: base de datos institucional (padrones de admisión) – Procesamiento de datos: Python, Pandas, Scikit-learn – Entrenamiento de modelos: XGBoost, LoRA vía Transformers (HuggingFace) – Evaluación automática: AUC-ROC, ROUGE, BERTScore, NDCG, MRR – Evaluación cualitativa: escala de satisfacción (Likert), revisión por expertos</p> |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|